

# Filtrado adaptativo

Lorena Álvarez Pérez

Universidad Carlos III de Madrid

Curso académico 2023/2024

# Índice

- 1 Introducción al filtrado adaptativo
- 2 Descenso por máxima pendiente
- 3 El algoritmo LMS

# Hasta ahora...

- Habíamos asumido que la señal de entrada al filtro ( $x[n]$ ) y la señal deseada ( $d[n]$ ) eran **procesos estocásticos estacionarios en sentido amplio (WSS)**.
  - El filtro se podía estudiar como un sistema LTI
- ¿Cómo se diseña el filtro cuando las señales no son estacionarias?
  - Si dividimos la señal en tramos que puedan “considerarse” estacionarios y calcular los coeficientes del filtro para cada trama de forma independiente...
    - Si los procesos estocásticos son de variación muy rápida, los intervalos donde asumimos estacionariedad serán demasiados cortos  $\Rightarrow$  estimaciones poco eficientes de los parámetros de estudio.
    - Tratar de modo independiente los intervalos, dificulta el análisis de la señal de modo completo.
- **¡Solución! Filtrado adaptativo**

# Punto de partida

- Filtro FIR óptimo cuando la señal de entrada ( $x[n]$ ) y señal deseada ( $d[n]$ ) son procesos estocásticos estacionarios WSS:

$$\mathbf{w} = \mathbf{R}_X^{-1} \mathbf{r}_{X,D}$$

- Si los procesos varían con el tiempo, la matriz de autocorrelación de la señal de entrada  $\mathbf{R}_X$ , y el vector de correlación cruzada entre la señal de entrada y la señal deseada  $\mathbf{r}_{X,D}$ , serán variantes en el tiempo.

$$\begin{cases} \mathbf{R}_X[n] \\ \mathbf{r}_{X,D}[n] \end{cases} \Rightarrow \mathbf{w}[n] \text{ (el filtro también es función del tiempo)}$$

¿Un **filtro de Wiener** para cada instante  $n$ ?

¡**Poca aplicación práctica!** Si en escenarios estacionarios era difícil conseguir una caracterización completa de las funciones de autocorrelación, para cada instante se torna más inviable aún.

# Obtención coeficientes - diseño incremental

- Partimos de que en el instante  $n$ , tendremos un vector de pesos  $\mathbf{w}[n]$ .
- El vector de pesos correspondiente al instante  $n + 1$ , se calcula como:

$$\mathbf{w}[n + 1] = \mathbf{w}[n] + \Delta\mathbf{w}[n]$$

- **Objetivo:** diseñar el **algoritmo para construir  $\Delta\mathbf{w}[n]$**
- Propiedades “deseables” de dicho algoritmo:
  - En un problema estacionario, el filtro adaptativo debería producir una secuencia de actualizaciones de  $\mathbf{w}[n]$  que converja al filtro óptimo:

$$\lim_{n \rightarrow \infty} \mathbf{w}[n] = \mathbf{R}_X^{-1} \mathbf{r}_{X,D}$$


(se podría usar el filtro adaptativo en escenarios estacionarios, ahorrando la inversión de la matriz de autocorrelación).

- No deberían tener que calcularse  $\mathbf{R}_X[n]$  ni  $\mathbf{r}_{X,D}[n]$
- Con señales no estacionarias, el filtro debería ser capaz de adaptarse a los cambios en los estadísticos de las señales y realizar un seguimiento de la solución a medida que ésta evoluciona con el tiempo.

# Esquema de un filtro adaptativo

El funcionamiento del filtro se divide en tres fases:

- Predicción: Cuando llega el vector  $\mathbf{x}[n]$ , el filtro realiza una predicción de la señal deseada  $\hat{d}[n] = \mathbf{w}[n]^T \mathbf{x}[n]$
- Cálculo de error: Se le comunica al filtro el valor real de  $d[n]$  y se calcula el error cometido por el filtro en la muestra:  $e[n] = d[n] - \hat{d}[n]$ .
- Actualización: A partir de  $e[n]$ , se obtiene la actualización  $\Delta \mathbf{w}[n]$  y, a continuación, los coeficientes  $\mathbf{w}[n+1]$  que se usarán para procesar  $\mathbf{x}[n+1]$  que representa la observación que llega en el instante  $n+1$ .



# Introducción

- Método iterativo de actualización del vector de pesos que considera la potencia del error de reconstrucción como una función de los pesos del filtro.
- Las actualizaciones del vector de pesos han de ir en la dirección de encontrar el mínimo de esta superficie de error.
- Sea  $\xi[n] = \mathbb{E}\{e^2[n]\}$  (donde  $e[n]^2 = f(\mathbf{w})$ ):
  - La dirección de máxima variación de  $\xi[n]$  con  $\mathbf{w}[n]$  viene dada por  $\nabla_{\mathbf{w}}\xi[n]$ .
  - Como nos interesa minimizar  $\xi[n]$ , la mejor actualización (para vector de pesos) es en la dirección opuesta al gradiente,  $-\nabla_{\mathbf{w}}\xi[n]$ .
  - Regla de actualización:

$$\mathbf{w}[n+1] = \mathbf{w}[n] - \frac{\mu}{2} \nabla_{\mathbf{w}}\xi[n]$$

(desde la posición actual,  $\mathbf{w}[n]$ , se da un paso de magnitud  $\frac{\mu}{2}$  en la dirección dada por  $-\nabla_{\mathbf{w}}\xi[n]$ ).

A la constante  $\mu$  se le conoce como paso de actualización.

# Cálculo del gradiente

- El cálculo del gradiente  $\nabla_{\mathbf{w}}\xi[n]$  se realiza a partir de la definición del error de reconstrucción:  $e[n] = d[n] - \hat{d}[n] = d[n] - \mathbf{w}^T \mathbf{x}[n]$ .

$$\begin{aligned}\nabla_{\mathbf{w}}\xi[n] &= \nabla_{\mathbf{w}}\mathbb{E}\{e[n]^2\} = \mathbb{E}\{\nabla_{\mathbf{w}}e[n]^2\} = \mathbb{E}\{\nabla_{\mathbf{w}}(d[n] - \mathbf{w}^T \mathbf{x}[n])^2\} \\ &= -2\mathbb{E}\{(d[n] - \mathbf{w}^T \mathbf{x}[n])\mathbf{x}[n]\} \\ &= -2\mathbb{E}\{e[n]\mathbf{x}[n]\}\end{aligned}$$

(Función de coste derivable  $J(\mathbf{w})$ , tal que para la solución óptima  $\mathbf{w}_0$ , se cumple que:  $J(\mathbf{w}_0) < J(\mathbf{w})$ ).

- Por tanto, la regla de actualización de descenso por máxima pendiente será:

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu\mathbb{E}\{e[n]\mathbf{x}[n]\}$$



## Aplicación al filtro de Wiener

- La regla de descenso por máxima pendiente puede utilizarse en un caso de filtrado estacionario donde no convenga invertir las matrices de autocorrelación.
- Las actualizaciones vendrán dadas por:

$$\begin{aligned}
 \mathbb{E}\{e[n]\mathbf{x}[n]\} &= \mathbb{E}\{(d[n] - \mathbf{w}[n]^T \mathbf{x}[n])\mathbf{x}[n]\} \\
 &= \mathbb{E}\{(d[n]\mathbf{x}[n] - \mathbf{x}[n]^T \mathbf{x}[n]\mathbf{w}[n])\} \\
 &= \mathbb{E}\{d[n]\mathbf{x}[n]\} - \mathbb{E}\{\mathbf{x}[n]^T \mathbf{x}[n]\}\mathbf{w}[n] \\
 &= \mathbf{r}_{D,X} - \mathbf{R}_X \mathbf{w}[n]
 \end{aligned}$$

- El algoritmo de descenso por máxima pendiente será:

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu(\mathbf{r}_{D,X} - \mathbf{R}_X \mathbf{w}[n])$$

Cuando el algoritmo encuentre un vector de pesos  $\mathbf{w}[n]$  que coincida con el filtro de Wiener, el algoritmo se detiene, ya que el filtro de Wiener verifica que:

$$\mathbf{w}[n] = \mathbf{R}_X^{-1} \mathbf{r}_{D,X}$$

y el término de actualización sería nulo.

## Paso de actualización

- Puede demostrarse que en escenarios estacionarios, el filtro adaptativo actualizado mediante el algoritmo de descenso por máxima pendiente converge al filtro óptimo si el paso de adaptación cumple:

$$0 < \mu < \frac{2}{\lambda_{max}}$$

donde  $\lambda_{max}$  es el autovalor más grande de  $\mathbf{R}_X$ .

# Consideraciones

- El algoritmo de descenso por máxima pendiente es de **poca utilidad práctica**.
- Es necesario calcular  $\mathbb{E}\{e[n]\mathbf{x}[n]\}$  y en la mayor parte de las aplicaciones, estos estadísticos se desconocen y deben estimarse a partir de los datos:
  - En casos estacionarios, las estimaciones de la autocorrelación de  $X_n$  y de la correlación cruzada entre  $X_n$  y  $D_n$  a partir de muestras, pueden ser más o menos, robustas.
  - En casos no estacionarios, es imposible conseguir estimaciones razonables de estos parámetros.

# Introducción

- Una estrategia razonable puede ser sustituir dicha esperanza por una media muestral, calculada a partir de  $L$  observaciones previas de la señal de entrada, es decir,  $x[n]$ ,  $x[n-1]$ ,  $x[n-2]$ ,  $\dots$ ,  $x[n-L+1]$ , para obtener así estimaciones muestrales de dichos estadísticos:

$$\mathbb{E}\{e[n]\mathbf{x}[n]\} \approx \frac{1}{L} \sum_{l=0}^{L-1} e[n-l]\mathbf{x}[n-l]$$

- Nótese que hay una diferencia significativa entre  $L$  (número de instantes de tiempo que se utiliza para estimar los estadísticos) y  $P$  (número de coeficientes del filtro). En general,  $L \gg P$ .
  - $P$  hace referencia al número de valores significativos de la función de autocorrelación para procesos estocásticos.
  - $L$  denota el número de instantes de tiempo en los que se puede suponer que los estadísticos de estos procesos pueden considerarse estacionarios.

# Introducción

- Caso particular:  $L = 1$  (**algoritmo LMS**, del inglés *Least-Mean-Square algorithm*)<sup>1</sup>.
  - Se utiliza el vector de entrada  $\mathbf{x}[n]$  y error de reconstrucción actual  $e[n]$  para realizar una estimación de rango uno de  $\mathbb{E}\{E[n]X[n]\}$ .
  - Ecuación de actualización:

$$\mathbf{w}[n+1] = \mathbf{w}[n] - \mu e[n] \mathbf{x}[n]$$

¡Observe que esta regla de actualización involucra vectores!

$$\begin{bmatrix} w_0[n+1] \\ w_1[n+1] \\ \vdots \\ w_{M-1}[n+1] \end{bmatrix} = \begin{bmatrix} w_0[n] \\ w_1[n] \\ \vdots \\ w_{M-1}[n] \end{bmatrix} + \begin{bmatrix} \mu e[n] x[n] \\ \mu e[n] x[n-1] \\ \vdots \\ \mu e[n] x[n-P+1] \end{bmatrix}$$

<sup>1</sup>Fue inventado en 1960 por Bernard Widrow (profesor de la Universidad de Stanford) y su primer estudiante de doctorado (Ted Hoff).

## Parámetro de actualización

- La convergencia del algoritmo LMS al filtro óptimo, en situaciones estacionarias, depende del parámetro  $\mu$  (determina la magnitud de cada paso de actualización en la dirección opuesta al gradiente).
- El LMS converge *en la media al cuadrado* a la solución de Wiener si:
  - Se da independencia estadística entre el vector de pesos  $\mathbf{w}[n]$  y los datos  $\mathbf{x}[n]$
  - El paso de actualización ( $\mu$ ) verifica:

$$0 < \mu < \frac{2}{P\mathbb{E}\{x[n]^2\}}$$

donde  $P$  es el orden del filtro. En aplicaciones prácticas,  $\mathbb{E}\{x[n]^2\}$  puede estimarse a partir de  $N$  valores de la señal  $x[n]$  mediante:

$$\mathbb{E}\{x[n]^2\} \approx \frac{1}{N} \sum_{k=0}^{N-1} x[k]^2$$